


PREPROCESAMIENTO DE DATOS DE TRÁFICO METR-LA Y PEMS-BAY

REPORTE TÉCNICO
PREPROCESAMIENTO DE DATOS DE TRÁFICO CON
METR-LA Y PEMS-BAY


ALLISON FERNANDA GARCIA REYES
FECHA: 29/01/26

INTRODUCCIÓN

El tráfico urbano genera grandes volúmenes de datos en tiempo real a través de sensores distribuidos en distintas ciudades. Para que estos datos puedan ser analizados correctamente, es necesario aplicar un proceso previo llamado preprocesamiento. En este proyecto se describe cómo se prepararon datos de velocidad del tráfico y datos de incidentes, con el fin de obtener información organizada y confiable para análisis posteriores.



(a) METR-LA



(b) PEMS-BAY

DATASETS UTILIZADOS

Para esta investigación se utilizaron los datasets METR-LA y PEMS-BAY, los cuales contienen datos de velocidad del tráfico recopilados por sensores urbanos. Estos sensores registran información en intervalos de cinco minutos y son ampliamente utilizados en estudios de análisis y predicción de tráfico.

DATASET COMPLEMENTARIO

Además de los datos principales de tráfico, se utilizó un dataset complementario de incidentes de tráfico. Este dataset incluye la fecha, la hora y una descripción textual del evento, como accidentes u otros incidentes viales, lo que permite contextualizar los cambios en la velocidad del tráfico.

LIMPIEZA DE DATOS

En la etapa de limpieza de datos se eliminaron todos los registros que contenían valores faltantes o nulos. Este paso es fundamental para garantizar la consistencia y confiabilidad de la información, ya que los datos incompletos pueden afectar negativamente los resultados del análisis.

CONVERSIÓN DE FECHAS Y HORAS

- Se unificó el formato de fecha y hora.
- Se creó una columna datetime.
- Permite alinear correctamente los datasets.

Código utilizado en python:

```
import pandas as pd

# Cargar datos
traffic = pd.read_csv("traffic_speed.csv")
accidents = pd.read_csv("traffic_accidents.csv")

# Limpieza de datos
traffic = traffic.dropna()
accidents = accidents.dropna()

# Conversión a fecha y hora
traffic["datetime"] = pd.to_datetime(traffic["datetime"])
accidents["datetime"] = pd.to_datetime(
    accidents["date"] + " " + accidents["time"]
)
```

ALINEACIÓN Y TABLA MAESTRA

La unión de datasets se realiza usando la columna datetime como referencia temporal común. Esto permite integrar los datos de velocidad del tráfico con los incidentes viales para cada instante de tiempo. Cuando no existe un registro de incidente, se asigna una etiqueta de tráfico normal, evitando la pérdida de información y manteniendo la continuidad de la serie temporal. Como resultado, se obtiene una tabla maestra que concentra en una sola estructura los datos numéricos y textuales necesarios para el análisis.

Código de unión:

```
data = pd.merge(
    traffic,
    accidents[["datetime", "description"]],
    on="datetime",
    how="left"
)

# Rellenar valores sin incidente
data["description"] = data["description"].fillna("Normal traffic flow")
```


RESAMPLING (SERIES DE TIEMPO)

El resampling permite reagrupar datos de series temporales en intervalos de tiempo uniformes. En los datos de tráfico, esta técnica ayuda a manejar registros con alta frecuencia o tiempos irregulares. En la investigación, los datos se agruparon en intervalos de cinco minutos, usando el promedio de la velocidad, lo que reduce el ruido y mejora la estabilidad de la serie temporal. Además, genera una estructura temporal homogénea, facilitando comparaciones y su uso en análisis estadísticos o modelos predictivos.

Código de resampling:

```
data_5min = data.resample("5T", on="datetime").mean()
```

RESULTADOS OBTENIDOS

El preprocesamiento dio como resultado una tabla final integrada con información temporal, velocidades del tráfico y descripciones de incidentes, que constituye el principal producto del entregable. Esta estructura permite identificar cambios en la velocidad asociados a incidentes y periodos sin eventos, proporcionando datos organizados y consistentes, listos para análisis posteriores, sin buscar aún conclusiones definitivas.

Ejemplo de tabla final:

Fecha y Hora	Velocidad	Descripción
2017-01-01 08:00:00	45.2	Normal traffic flow
2017-01-01 08:05:00	42	Accident on highway

CONCLUSIÓN

Como parte de este entregable de investigación, se documentó de manera detallada la etapa de preprocesamiento de datos de tráfico. Se aplicaron técnicas de limpieza, conversión temporal, alineación de datasets y resampling, obteniendo una tabla estructurada y coherente. Este avance establece una base metodológica sólida para investigaciones futuras relacionadas con el análisis y la predicción del tráfico urbano.

G R A C I A S

REFERENCIAS

- METR-LA DATASET - IEEE DATAPORT
- PEMS-BAY DATASET - TRÁFICO URBANO
- REPOSITARIOS PÚBLICOS DE INCIDENTES DE TRÁFICO

PREPROCESAMIENTO DE RELACIONES MEDIANTE MATRIZ ADYACENTE, MAPA DE CALOR Y RUIDO GAUSSIANO

REPORTE TÉCNICO (2DA ENTREGA)
PREPROCESAMIENTO DE DATOS DE TRÁFICO CON
METR-LA Y PEMS-BAY

ALLISON FERNANDA GARCIA REYES
FECHA: 08/02/26


INTRODUCCIÓN

El preprocesamiento de datos es una etapa fundamental en cualquier análisis de datos, ya que permite transformar la información cruda en una representación estructurada, consistente y adecuada para su análisis posterior. En contextos como el análisis de redes, ciencia de datos y aprendizaje automático, no solo es necesario limpiar y alinear los datos, sino también preprocesar las relaciones entre los elementos del sistema.

En este trabajo, las relaciones se representan mediante una matriz adyacente, la cual es posteriormente visualizada mediante un mapa de calor. Además, se aplica ruido gaussiano como técnica de preprocesamiento para introducir variabilidad controlada y mejorar la robustez de la representación.



MATRIZ ADYACENTE COMO REPRESENTACIÓN DE RELACIONES



CONCLUSIÓN

LA MATRIZ ADYACENTE PROPORCIONA UNA REPRESENTACIÓN ESTRUCTURADA DE LAS RELACIONES ENTRE NODOS, MIENTRAS QUE EL MAPA DE CALOR PERMITE UNA INTERPRETACIÓN VISUAL EFICIENTE DE DICHAS RELACIONES. LA INCORPORACIÓN DE RUIDO GAUSSIANO COMO TÉCNICA DE PREPROCESAMIENTO INTRODUCE VARIABILIDAD CONTROLADA, MEJORANDO LA ROBUSTEZ Y REALISMO DE LOS DATOS. EN CONJUNTO, ESTAS TÉCNICAS FORMAN UNA BASE SÓLIDA PARA EL ANÁLISIS EXPLORATORIO Y EL PROCESAMIENTO POSTERIOR DE LOS DATOS.

REFERENCIAS

- BISHOP, C. M. (2006). PATTERN RECOGNITION AND MACHINE LEARNING. SPRINGER.
- HASTIE, T., TIBSHIRANI, R., & FRIEDMAN, J. (2009). THE ELEMENTS OF STATISTICAL LEARNING. SPRINGER.>
- AGGARWAL, C. C. (2015). DATA MINING: THE TEXTBOOK. SPRINGER.
- NEWMAN, M. (2018). NETWORKS. OXFORD UNIVERSITY PRESS.
- MCKINNEY, W. (2017). PYTHON FOR DATA ANALYSIS. O'REILLY MEDIA.

PREPROCESAMIENTO DE DATOS DE TRÁFICO MEDIANTE ALINEACIÓN TEMPORAL Y GENERACIÓN DE DESCRIPCIONES TEXTUALES SINTÉTICAS EN LOS DATASETS METR-LA Y PEMS-BAY

REPORTE TÉCNICO (3RA ENTREGA)

PREPROCESAMIENTO DE DATOS DE TRÁFICO CON METR-LA Y PEMS-BAY

ALLISON FERNANDA GARCIA REYES

FECHA: 19/02/26

PLANTEAMIENTO DEL PROBLEMA:

Los datasets de tráfico METR-LA y PEMS-BAY contienen únicamente información numérica sobre la velocidad del tráfico, lo cual limita su interpretación y uso en análisis más completos. La ausencia de información textual sobre incidentes dificulta la comprensión del comportamiento del tráfico y su relación con eventos externos, por lo que se requiere un proceso de preprocesamiento que permita limpiar, alinear y enriquecer dichos datos.

OBJETIVO GENERAL:

Desarrollar un proceso de preprocesamiento que permita limpiar, alinear temporalmente y enriquecer los datos de tráfico de los datasets METR-LA y PEMS-BAY mediante la integración de información numérica y descripciones textuales.

OBJETIVOS ESPECÍFICOS:

- Limpiar los datos eliminando valores nulos.
- Unificar el formato de fecha y hora para permitir la alineación temporal.
- Construir una tabla maestra que integre la velocidad del tráfico y la descripción del incidente.
- Aplicar resampling para agrupar los datos en intervalos de cinco minutos.

HIPOTESIS:

La aplicación de técnicas de preprocesamiento como limpieza, alineación temporal y generación de descripciones textuales mejora la estructura y consistencia de los datos de tráfico, facilitando su análisis posterior.

VARIABLES:

Tipo de variable	Variable
Independiente	Proceso de preprocesamiento de datos
Dependiente	Calidad y estructura de los datos de tráfico

OPERACIONALIZACIÓN DE VARIABLES

VARIABLE INDEPENDIENTE: PROCESO DE PREPROCESAMIENTO DE DATOS

Dimensión	Indicador	Técnica / Instrumento
Limpieza de datos	Eliminación de valores nulos	Python – Pandas
Alineación temporal	Unificación de fecha y hora	Python – Pandas
Integración de datos	Construcción de tabla maestra	Análisis computacional
Resampling	Agrupación en intervalos de 5 minutos	Análisis de series de tiempo

VARIABLE DEPENDIENTE: CALIDAD Y ESTRUCTURA DE LOS DATOS DE TRÁFICO

Dimensión	Indicador	Técnica / Instrumento
Consistencia	Ausencia de valores nulos	Validación del DataFrame
Integración multimodal	Presencia de datos numéricos y textuales	Revisión estructural
Preparación para análisis	Datos listos para análisis posterior	Evaluación final

REFERENCIAS

- IEEE DataPort. (s.f.). METR-LA Traffic Dataset. Repositorio académico de datos de tráfico urbano.
- IEEE DataPort. (s.f.). PEMS-BAY Traffic Dataset. Conjunto de datos de velocidad de tráfico recopilados por sensores en tiempo real.
- Kaggle. (s.f.). Traffic Accidents Dataset. Dataset complementario con descripciones textuales de incidentes de tráfico.
- Pandas. (s.f.). Pandas Documentation. Biblioteca utilizada para la limpieza, alineación temporal y manipulación de datos.
- Python. (s.f.). Python Documentation. Lenguaje de programación utilizado para el preprocesamiento de datos.
- Material introductorio de Ingeniería de Datos y análisis de series de tiempo, utilizado como base teórica para los procesos de limpieza, resampling y estructuración de datos.